

18:08 KST

v5 한국어 논문형 보고서 초안

작성 상태: execution draft, 2026-06-28 refresh 기준

이 문서는 최종 발표와 보고서 작성을 위한 한국어 논문형 원고 초안이다. 숫자와

claim 은 현재 측정된 artifact 만 반영하며, after-MLM 및 downstream 결과는 matched

v5_random/v5_fvt checkpoint 와 aggregation row 가 생기기 전까지 조건부로 둔다.

현재 checkpoint 진행률과 post-checkpoint Go/No-Go 는 이 정적 원고 header 가 아니라

../final_action_dashboard_ko.md 와

bash scripts/run_v5_post_checkpoint_evals.sh status 출력을 우선한다.

관련 gate:

- claim boundary: claim_ledger.md
- method comparison: ../method_comparison_summary.md
- post-result patch plan: ../post_result_patch_plan_ko.md
- final claim rule: ../final_claim_decision_tree.md
- outcome matrix: ../post_checkpoint_outcome_matrix_ko.md
- final claim freeze audit: ../final_claim_freeze_audit.md
- final package audit: ../reporting_package_audit.md

초록

본 연구는 Glot500 의 multilingual vocabulary expansion 및 continued MLM

pretraining 흐름을 통제된 102 개 language-script 설정에서 재연하고, vocabulary extension 이후 새 embedding row 를 어떻게 초기화할지 비교한다. 실험 데이터는 XLM-R seen Glot500 language-script 92 개와 Glot500 내부 raw corpus 에서 선택한 target language-script 10 개로 구성된다. target10 은 모두 XLM-R seen language 가 아니며, 30,000 sentence 이상 조건과 raw directory 존재 조건을 만족한다.

핵심 novelty 는 새로운 corpus 나 task 가 아니라, 확장된 vocabulary row 의 initialization 이다. Glot500-style random resize baseline 과 비교하여, source-token decomposition 기반 FVT 초기화가 zero-step MLM proxy 에서 더 좋은 초기 상태를 만드는지 확인한다. 현재까지 full tokenizer, initialization audit, zero-step evaluation 은 완료되었고, FVT 는 v5 target group weighted NLL 에서 random 대비 9.626238 낮은 값을 보였다. 다만 after-MLM PPPL 과 downstream transfer claim 은 matched checkpoint 및 downstream parsing 완료 후에만 승격한다.

1. 서론

다국어 사전학습 모델은 수백 개 언어를 지원하지만, 실제 성능은 tokenizer coverage, script, corpus size, related language support 에 크게 좌우된다. Glot500 은 더 많은 language-script corpus 와 vocabulary expansion, continued pretraining 을 통해 이 문제를 다룬다. 본 프로젝트는 전체 511 개 언어의 full reproduction 을 목표로 하지 않고, 계산 가능한 subset 에서 Glot500 의 핵심 실험 구조를 충실히 재연한다.

본 실험의 질문은 다음과 같다.

1. Glot500-style tokenizer expansion 과 continued MLM 을 92+10 subset 에서 재연할 수 있는가?

1. vocabulary extension 이후 새 token embedding row 를 random 으로 둘 때와 source-token decomposition 으로 초기화할 때 zero-step 및 after-MLM behavior 가 달라지는가?

1. MLM proxy 의 차이가 Glot500 downstream metric replay 에서도 관찰되는가?

1.1 기여 요약

본 보고서의 기여는 세 가지로 정리한다.

첫째, Glot500 의 full-scale claim 을 과장하지 않고, 92 개 XLM-R-seen language-script 와 10 개 Glot500-internal target language-script 로 구성된 controlled replay package 를 구축한다. 이 package 는 corpus merge, SentencePiece append tokenizer, continued MLM, metric-family coverage, claim freeze audit 를 함께 묶어 재연 범위를 artifact 단위로 검증한다.

둘째, vocabulary extension 이후 새 embedding row initialization 을 독립된 방법론 축으로 분리한다. source-token decomposition 기반 FVT 는 source row identity, <mask> remap, byte row accounting, LM-head tying 을 보존하면서 zero-step target MLM proxy 에서 random resize 보다 낮은 weighted NLL 을 보인다.

셋째, Glot500 downstream task family 를 생략하지 않고 local coverage 와 blocker 를 명시한다. 따라서 최종 claim 은 PPPL, retrieval, classification, tagging, Roundtrip

alignment 가 aggregation 에 들어온 뒤에만 승격되며, target10 downstream coverage 가 없는 metric 은 limitation 으로 남긴다.

2. 재연 범위와 방법론 위치

본 실험은 full Glot500 reproduction 이 아니라 controlled subset reproduction 이다.

따라서 허용되는 표현은 다음과 같다.

- 허용: Glot500-style pipeline 을 102-language subset 에서 재연했다.
- 불가: Glot500 511-language experiment 를 완벽히 재현했다.

tokenization 측면에서 V4/V5 는 Glot500-style 이다. auxiliary SentencePiece model 을

학습하고, XLM-R SPM 에 없는 piece 를 기존 SPM 뒤에 append 한다. 반면 V3 는 기존

tokenizer 에 새 token 을 추가하는 Yamaguchi-style vocabulary expansion ablation 에

가깝다. 이 구분 덕분에 reproduction axis 와 novelty axis 가 분리된다. reproduction 은

Glot500-style tokenizer/continued MLM 이고, novelty 는 appended row initialization 이다.

2.1 Glot500 과 본 연구의 관계

Glot500 은 language-script coverage 를 넓히고, tokenizer vocabulary 를 확장한 뒤,

continued pretraining 과 downstream evaluation 으로 low-resource multilingual model 의

효과를 검증한다. 본 연구는 이 전체 규모를 다시 학습하지 않는다. 대신 Glot500 의 핵심

실험 논리를 보존한다. 즉, corpus scope 를 고정하고, SentencePiece 기반 vocabulary

expansion 을 수행하고, continued MLM 으로 representation 을 갱신하고, Glot500 에서 사용한

metric family 를 유지한다.

따라서 v5 의 contribution 은 "더 큰 Glot500"이 아니라, Glot500-style pipeline 을 작고

검증 가능한 subset 으로 재연하면서 vocabulary expansion 이후 initialization 이라는

새 질문을 붙이고, 두 방법론 축을 분리해 분석하는 데 있다. 재연 fidelity 의 세부

구분은 다음 표에 고정한다.

`docs/exp/v5/4_reporting/00_tables/table_15_glot500_reproduction_fidelity.md`

전체 실험 흐름을 요약한 overview figure 는 다음 파일에 둔다.

`docs/exp/v5/4_reporting/01_figures/generated/figure_01_experiment_pipeline.png`

요약하면 v5 는 experimental logic 수준에서는 충실하다. Glot500-internal data,

SentencePiece append, continued MLM, metric-family accounting, head/tail/all-style

reporting 을 유지한다. 다만 full 511-language scale 과 original compute budget 은

의도적으로 재연하지 않는다.

2.2 Yamaguchi-style Vocabulary Expansion 과의 관계

Yamaguchi 계열 방법은 적은 target-language text 로 vocabulary 를 확장하고, 추가된 token

embedding 을 어떻게 초기화할지 다룬다는 점에서 본 연구의 novelty axis 와 연결된다. 다만

v5 tokenizer 자체는 V3 식 `add_tokens ( )` route 가 아니라 Glot500-style SPM append route 를

사용한다. 따라서 Yamaguchi-style 은 v5 의 tokenizer reproduction method 가 아니라,

새 vocabulary row initialization 을 비교하는 motivation 과 ablation framing 에 가깝다.

이 구분은 보고서와 발표에서 중요하다. tokenizer method 를 Yamaguchi method 라고 부르면

Glott500 재연성이 흐려지고, 반대로 initialization novelty 를 Glott500 reproduction 만으로

설명하면 본 연구의 방법론적 기여가 약해진다.

3. 데이터

head group 은 XLM-R seen Glot500 language-script 중 local raw directory 가 존재하는

92 개이다. target group 은 Glot500 raw 안에 있으면서 XLM-R seen 이 아니고,

new length 가 30,000 이상인 후보 중 지역, 문자, 어족 다양성을 고려해 고른 10 개이다.

target10:

- fur_Latn: Friulian, Europe, Latin
- krc_Cyrl: Karachay-Balkar, North Caucasus, Cyrillic
- acm_Arab: Mesopotamian Arabic, West Asia, Arabic
- dzo_Tibt: Dzongkha, Himalaya, Tibetan
- sat_Olck: Santali, South Asia, Ol Chiki
- mad_Latn: Madurese, Southeast Asia, Latin
- bam_Latn: Bambara, West Africa, Latin
- kjb_Latn: Q'anjob'al, Mesoamerica, Latin
- quw_Latn: Tena Lowland Quichua, Andean South America, Latin
- rap_Latn: Rapanui, Polynesia, Latin

main merge 는 92,452,251 lines 로 완료되었고, missing language directory 는 0 개였다.

이 값은 ../../0_tokenizer/merge/Glot500_v5_glot50010_xlmr100.report.json
과

../../0_tokenizer/merge/Glot500_v5_glot50010_xlmr100.manifest.tsv 에서
확인한다.

4. 방법

4.1 Tokenizer Expansion

full corpus 에서 Glot500-style auxiliary SentencePiece tokenizer 를 학습한 뒤,

XLM-R-base tokenizer 에 없는 pieces 를 append 했다. 최종 tokenizer 는 368,687 HF tokens 를

가지며, XLM-R 대비 118,685 token strings 가 추가되었다. <mask> id 는 source

250001 에서 target 368686 으로 이동했으므로, embedding 복사는 id prefix 가 아니라 token

identity 기준으로 수행해야 한다.

main tokenizer audit 은 20 개 head language 와 10 개 target language 에서 failure 0 으로

통과했다. audited 30 개 언어 중 29 개는 tokens/word 가 감소했다. target10 에서는 9 개

언어가 개선되었고, dzo_Tibt 는 여전히 regression case 로 남았다. 이 regression 은

보고서에서 failure 를 숨기지 않고 score calibration 및 newly appended Tibetan piece 의

영향으로 분석한다.

4.2 Embedding Initialization

비교 대상은 다음과 같다.

Method	Description	Role
random	Hugging Face resize 기본 random row	Glot500-style baseline
mean	source/global mean 기반 초기화	simple ablation

Method	Description	Role
fvt	target token surface 를 source tokenizer 로 분해하고 source embedding 평균 사용	main novelty
align	script/character-aware fallback	exploratory ablation

main checkpoint initialization audit 에서 v5_fvt 는 118,427 개 새 row 를

source-token decomposition 으로 초기화했고, 256 byte rows 와 2 lexical fallback rows 는

global mean 을 사용했다. source identity rows 250,002 개가 보존되었고, <mask> remap

max absolute difference 는 0.0 이며, LM head tying 도 true 로 확인되었다.

4.3 Continued MLM

continued MLM 은 동일한 corpus, tokenizer, seed, schedule, checkpoint rule 로

v5_random 과 v5_fvt 를 paired comparison 한다. 이 단계의 핵심은 long training 후

성능만 보는 것이 아니라, zero-step, early-step, selected checkpoint 를 분리해서

initialization effect 가 언제 살아 있는지 확인하는 것이다.

현재 상태에서는 paired 10K MLM run 이 진행 중이며, matched checkpoint 가 준비되기 전에는

after-MLM claim 을 승격하지 않는다.

4.4 Evaluation

Glott500 에서 측정한 metric family 는 v5 에서도 모두 required 로 둔다.

Metric family	Required	Current interpretation
Pseudoperplexity / MLM	yes	target10 까지 raw-text 평가 가능

Metric family	Required	Current interpretation
proxy		
Tatoeba retrieval	yes	available-language replay, target10 coverage limited
Bible retrieval	yes	available-language replay, target10 coverage limited
Text classification	yes	local English split 중심
NER	yes	available-language replay
POS	yes	available-language replay
Roundtrip alignment	yes	XLM-R/Glot500-base/v5-random 측정 완료, FVT checkpoint 대기

coverage 가 없는 언어는 제외하지 않고, measured, excluded, blocked reason 을 기록한다.

따라서 downstream claim 은 target10 전체에 대한 직접 claim 이 아니라

available-language/head/all replay 로 해석해야 한다.

5. 현재 결과

5.1 Setup Fidelity

scope, merge, tokenizer, initialization 단계는 main experiment 기준으로 준비되었다.

핵심 값은 다음과 같다.

Item	Value
seen language-scripts	92

Item	Value
------	-------

target language-scripts 10

merged corpus lines 92,452,251

missing language dirs 0

final tokenizer size 368,687

appended token strings 118,685

5.2 Tokenizer Result

main tokenizer audit 은 failure 0 으로 통과했다. audited target10 중 9 개는 fertility 가

개선되었고, dzo_Tibt 는 regression 으로 남았다. 이 결과는 tokenizer expansion 의

전체 방향은 긍정적이지만, script-specific calibration 문제가 있을 수 있음을 보여준다.

정량적으로는 audited 30 개 언어 중 29 개가 개선되었고(29/30), target10 에서는 9 개가

개선되었다(9/10). dzo_Tibt 는 4.223938 -> 5.552124 tokens/word 로 악화되어

visible limitation 으로 유지한다.

5.3 Zero-Step Initialization Result

zero-step MLM proxy 에서 FVT 는 random resize 보다 명확히 좋은 초기 상태를 보였다. mean

initialization ablation 의 target weighted NLL 은 11.953142 로, random 보다는 좋지만 FVT 에는

미치지 못했다.

Split	random weighted NLL	FVT weighted NLL	Delta	Relative
head sample	12.895301	6.621457	-6.273844	-48.65%
v5 target	18.411756	8.785518	-9.626238	-52.28%
all	16.511807	8.040183	-8.471624	-51.31%

이 결과는 final downstream claim 이 아니라 intrinsic initialization evidence 이다.

after-MLM PPPL 과 downstream row 가 준비되면 이 효과가 유지되는지, 줄어드는지, 또는 task 별로 달라지는지 확인한다.

5.4 Baseline and External Reference Rows

현재 final result table 에 넣을 수 있는 measured row 는 XLM-R-base baseline 과

Glott500-base external reference 이다. Glott500-base 는 같은 budget 으로 재학습한 baseline 이 아니므로, equal-budget comparison 이 아니라 reference scale 로 해석한다.

Metric	XLM-R-base	Glott500-base	Interpretation
target PPPL	61.980216	15.102934	target raw-text intrinsic reference
Tatoeba all Top-10	0.566067	0.706649	available-language retrieval reference; v5-random 0.610353 measured
Bible all Top-10	0.381153	0.509356	available-language Bible retrieval reference; v5-random 0.328019 measured
Taxi1500 macro-F1	0.592876	0.743338	local text-classification reference; v5-random 0.702956 measured

Metric	XLM-R-base	Glott500-base	Interpretation
NER all F1	0.549858	0.627108	available-language tagging reference; v5-random 0.544628 measured
POS all F1	0.481336	0.567542	available-language tagging reference with local train-language caveat; v5-random 0.481102 measured
Roundtrip accuracy	0.185300	0.205189	available-language alignment reference; v5-random 0.190300 measured

추가로 v5_random after-MLM PPPL 은 측정 완료됐다. weighted PPPL 은 target10

39.222875, head 18.726452, all 20.138927 이다. 이 값은 random-initialized

checkpoint 의 measured row 이며, 아직 FVT 와의 method comparison claim 은 아니다.

v5_random Tatoeba retrieval 도 measured row 가 생겼다. Top-10 accuracy 는 head

0.700285, all available 0.610353 이다. target10 coverage 는 여전히 0/10 이므로

available-language downstream row 로만 해석한다.

v5_random Taxi1500 도 measured row 가 생겼다. macro-F1 은 0.702956, accuracy 는

0.747748 이다. local English-only classification row 이므로 target10 downstream

claim 으로 쓰지 않는다.

v5_random Roundtrip accuracy 도 available 74-language setting 에서 0.190300 으로

측정됐지만, FVT downstream row 가 없으므로 downstream method claim 은 여전히 잠겨 있다.

v5_random Bible Top-10 도 같은 available 74-language setting 에서 0.328019 로

측정됐다. 다만 FVT Bible row 가 없으므로 이것도 method win claim 으로 쓰지 않는다.

v5_random NER all F1 은 0.544628, head F1 은 0.608020 이며, POS all F1 은

0.481102, head F1 은 0.587430 이다. POS 는 baseline/reference 와 동일하게

TRAIN_LANGS=tur_Latn 조건에서 해석한다.

중간 해석은 분명하다. v5_random 은 method win 이 아니라 diagnostic lower-bound row 이다.

target10 PPPL 에서는 XLM-R 보다 좋아졌지만 Glot500-base reference 에는 아직 못 미치고,

head/all PPPL 에서는 두 reference 보다 나쁘다. Downstream 은 metric 별로 섞인다. Tatoeba 와

Taxi1500 에서는 XLM-R 보다 높지만 Glot500-base 에는 못 미치고, Bible retrieval 에서는 두

reference 보다 낮으며, POS head 에서는 두 reference 보다 높고, Roundtrip 에서는 XLM-R 과

Glot500-base 사이에 있다. 따라서 이 결과는 실험 설계를 약하게 만드는 것이 아니라,

matched v5_fvt 가 왜 결정적인 test 인지 보여준다.

이 표에서 아직 빠진 핵심 row 는 v5_fvt 의 after-MLM PPPL 및 available downstream

결과이다. 이 row 는 selected 10K checkpoint 가 생긴 뒤

scripts/run_v5_post_checkpoint_evals.sh wrapper 로만 채운다.

5.5 Current Finalization Gates

현재 결론 동결 상태는 ../final_claim_freeze_audit.md 가 관리한다. 현 단계에서

허용되는 결론은 setup fidelity 와 zero-step novelty 까지이다. after-MLM PPPL 개선,

downstream improvement, target10 downstream improvement 는 모두 locked claim 이다.

이 구조는 보수적이지만 발표 방어에는 유리하다. live training log 나 중간 dev score 가

좋아 보여도, aggregation 에 들어간 measured row 가 아니면 final report/PPT claim 으로 승격하지 않는다.

6. 논의

현재까지 가장 강한 기여는 “Glott500-style vocabulary expansion 에서 새 row 를 random 으로 두지 않아도 된다” 는 실험적 근거이다. FVT 는 target token 을 기존 XLM-R tokenizer 로 분해한 뒤 source embedding 평균을 사용하므로, low-resource corpus 만으로도 더 안정적인 초기 embedding 을 제공할 수 있다.

다만 tokenizer 자체가 모든 언어에서 균일하게 이득을 주지는 않는다. dzo_Tibt 는 byte fallback 이나 <unk> 문제가 아니라 새 Tibetan pieces 의 segmentation score calibration 문제로 보인다. 이 failure case 는 오히려 발표에서 설득력 있는 분석 포인트가 된다. 좋은 실험은 성공만 있는 실험이 아니라, 어떤 조건에서 깨지는지도 보여준다.

7. Limitations

- v5 는 511-language full reproduction 이 아니라 102-language controlled subset 이다.
- PPPL 은 target10 coverage 10/10 이지만 retained downstream task coverage 는 target10 0/10 이므로 target10 downstream transfer 를 직접

주장하지 않는다.

- Roundtrip alignment 는 available-language 기준 XLM-R/Glott500-base/v5-random row 를

측정했지만, target10 coverage 는 0/10 이고 FVT method row 는 checkpoint 이후에만 확정한다.

- after-MLM 및 downstream novelty claim 은 matched v5_random/v5_fvt checkpoint

와

parsed aggregation row 이후에만 확정한다.

8. 결론 초안

현재 안전한 결론은 다음과 같다.

v5 는 Glot500-style tokenizer expansion, continued MLM 준비, evaluation family accounting 을 92+10 controlled subset 에서 충실히 재연하는 구조를 갖췄다. 또한 vocabulary extension 이후 source-token decomposition 기반 FVT initialization 은 zero-step MLM proxy 에서 random resize 보다 큰 이점을 보였다. 최종 after-MLM 및 downstream transfer 결론은 matched checkpoint 와 available-language metric replay 완료 후 결정한다.

8.1 결과별 최종 결론 선택 규칙

checkpoint 이후 초록과 결론은 새로 즉흥 작성하지 않고,

../post_checkpoint_outcome_matrix_ko.md 와

../final_claim_decision_tree.md 가

허용한 outcome 만 사용한다.

Outcome	조건	최종 report/PPT 문장 방향
bounded positive	FVT 가 after-MLM PPPL 과 available downstream 다수에서 우세	target10 coverage caveat 를 단 제한적 positive claim

Outcome	조건	최종 report/PPT 문장 방향
intrinsic positive, downstream mixed	FVT 가 PPPL 에서는 우세하지만 downstream 은 섞임	intrinsic adaptation 개선 claim, downstream 은 coverage-dependent
early-only diagnostic	zero-step 은 우세하지만 after- MLM 에서 우위가 사라짐	final superiority 가 아니라 early adaptation diagnostic
negative final comparison	PPPL/downstream 에서 random 이 같거나 우세	controlled negative result 와 추가 objective 필요성
incomplete evaluation	matched row 또는 parser output 이 완결되지 않음	execution draft 결론 유지, final method claim 잠금

최종 문장 승격 조건은 세 가지이다. 첫째, 3_evaluation/09_aggregation/에

v5_random 과 v5_fvt row 가 모두 있어야 한다. 둘째,

result_promotion_readiness_audit.md 가 결과 승격 가능 상태여야 한다. 셋째,

final_claim_freeze_audit.md 가 pending/disallowed claim 을 다시 잠금 상태여야 한다.

하나라도 충족되지 않으면 위 안전 결론을 유지한다.

9. 재현성 요약

실행 경로와 문서 source of truth:

- top-level plan: ../../Plan.md
- living report: ../../Report.md
- selected data manifest:

../../0_tokenizer/miscellaneous/glot50010_selected_manifest.tsv

- main merge report:

../../0_tokenizer/merge/Glot500_v5_glot50010_xlmr100.report.json

- metric mapping: ../../3_evaluation/metric_mapping.md
- aggregation folder: ../../3_evaluation/09_aggregation/
- post-checkpoint runner:
../../scripts/run_v5_post_checkpoint_evals.sh
- reporting refresh: ../../scripts/refresh_v5_reporting.py

최종 결과 반영 순서:

1. matched v5_random and v5_fvt checkpoints 를 확인한다.
2. ../../3_evaluation/post_checkpoint_eval_queue.md 에서 runnable metric rows 를 확인한다.
3. ../../3_evaluation/post_checkpoint_execution_plan.md 에서 launch env, output/log 위치,

promotion rule 을 확인한다.

1. post_checkpoint_preflight.md 가
post_checkpoint_preflight_ready_to_launch 를

보고한 뒤 guarded post-checkpoint runner 로 PPPL 및 available downstream rows 를 실행한다.

1. reporting refresh 를 실행한다.
2. ../../post_result_patch_plan_ko.md 에서 ready_for_patch 행만 보고서와 PPT 수정 대상으로 삼는다.
3. ../../final_claim_decision_tree.md 가 허용하는 conclusion wording 만 보고서와 PPT 에 반영한다.

checkpoint 가 준비된 뒤 실제 handoff 명령:

```
bash scripts/run_v5_post_checkpoint_evals.sh status
SKIP_MEASURED=1 WITH_PLOTS=1 GPU_RANDOM=0 GPU_FVT=1 bash
scripts/run_v5_post_checkpoint_evals.sh all
```

10. 참고문헌

본 한국어 원고의 citation boundary 는 `citation_source_map.md` 와 `external_source_verification.md` 를 따른다. 인용은 배경과 방법론 계보를 설명하기 위한 것이며, v5 의 수치 결과는 항상 local artifact 와 aggregation table 에서만 온다.

- Ayyoob ImaniGooghari et al. 2023. *Glott500: Scaling Multilingual Corpora and Language Models to 500 Languages*. ACL 2023.

<https://aclanthology.org/2023.acl-long.61/>,

DOI 10.18653/v1/2023.acl-long.61.

본 연구에서는 Glott500-style corpus/tokenizer/continued-MLM/evaluation 흐름의 reproduction target 으로 인용한다. v5 가 511-language full scale 을 재학습했다는 근거로 사용하지 않는다.

- Glott500 official code. <https://github.com/cisnlp/Glott500>.

inherited tokenizer/evaluation script lineage 를 설명하는 code reference 이다.

local v5 재현성 근거는 `reproducibility_appendix.md`, `source_map.md`, 그리고 generated audit files 에 둔다.

- Atsuki Yamaguchi, Aline Villavicencio, Nikolaos Aletras. 2026.

How Can We Effectively Expand the Vocabulary of LLMs with 0.01GB of Target Language Text? Computational Linguistics 52(1):295-330.

<https://aclanthology.org/2026.cl-1.9/>,

DOI 10.1162/coli.a.581.

본 연구에서는 low-resource vocabulary expansion 과 new-row initialization 문제의 inspiration/contrast 로 인용한다. v5 main tokenizer 는 Yamaguchi-style add-token route 가 아니라 Glot500-style SentencePiece append route 이다.

- Low-resource continued vocabulary expansion official code.

<https://github.com/gucci-j/lowres-cve>.

관련 구현 계보와 terminology bridge 로만 사용한다. 실행된 v5 pipeline 의 근거는 local scripts 와 generated artifacts 이다.