

XLM-R-Based Glot500-Style Vocabulary Extension for Low-Resource Tail Languages

Jongha Kim

Term Project Report Draft
July 2026

Abstract

본 보고서는 Glot500의 horizontal scaling 방향을 작은 재현 가능한 설정으로 가져와, XLM-R 기반 multilingual encoder를 low-resource tail language로 확장할 때 새 vocabulary embedding row의 초기화가 얼마나 중요한지 분석한다. 실험은 92개의 XLM-R-seen language-script와 downstream 평가가 가능한 7개의 XLM-R-unseen target language-script를 사용한다. Tokenizer는 Glot500과 같이 mixed corpus에서 SentencePiece unigram tokenizer를 학습하고 기존 XLM-R SentencePiece model 뒤에 새 piece를 append하는 방식으로 고정한다. 따라서 main ablation은 tokenizer 자체가 아니라 새 token embedding row의 initialization, 즉 RANDOM, MEAN, FVT, WEIGHTED FVT, FAMILY-AWARE MEAN의 차이이다.

최종 보고서는 50K-step convergence run을 중심으로 다섯 초기화 방법의 training loss, pseudoperplexity, downstream scores를 tail/head/all group으로 정리한다. Step-4000 결과는 수렴 결과가 아니라 early diagnostic evidence로만 사용한다. 이 구분은 중요하다. 4K 이하 checkpoint에서는 FVT가 target pseudoperplexity와 여러 retrieval/alignment task에서 강한 초기 신호를 보였지만, 최종 주장은 50K run에서 loss flattening과 downstream trajectory가 확인된 뒤에만 세운다. 따라서 본 보고서는 특정 initialization이 모든 task에서 항상 최고라고 주장하지 않는다. 대신 같은 tokenizer, corpus, MLM objective, evaluation protocol을 공유하는 controlled setup에서 새 token embedding initialization이 low-resource vocabulary adaptation의 수렴 양상과 평가 지표에 실질적인 영향을 주는지를 검증한다.

1 Introduction

Multilingual language model 연구는 크게 두 방향으로 확장되어 왔다. 하나는 모델 크기, 학습 데이터, 연산량을 키워 높은 성능을 얻는 vertical scaling이고, 다른 하나는 더 많은 언어와 script를 지원하도록 coverage 자체를 넓히는 horizontal scaling이다. Glot500은 후자에 속한다. 원 논문은 511개 언어를 포함하는 Glot500-c corpus를 구축하고, XLM-R-base를 vocabulary extension과 continued masked language modeling(MLM)으로 확장한 Glot500-m을 제안한다 [Imani et al., 2023, Conneau et al., 2020].

본 프로젝트의 훌륭한 점은 Glot500의 큰 그림을 그대로 반복하려 하기보다, 계산 가능한 범위에서 가장 불확실한 선택 하나를 분리했다는 데 있다. Glot500-style tokenizer 확장을 하면 기존 XLM-R vocabulary에 없던 token들이 embedding matrix 뒤에 새 row로 추가된다. 문제는 이 row를 어떻게 시작하느냐이다. 충분히 긴 pretraining을 한다면 random initialization도 학습될 수 있지만, low-resource language와 짧은 continued pretraining budget에서는 초기값의 영향이 오래 남을 수 있다.

본 보고서는 다음 질문을 다룬다.

1. Glot500-style SentencePiece append 방식은 target tail language의 subword fragmentation을 줄이는가?
2. 같은 tokenizer와 corpus를 고정했을 때, 새 token row initialization만 바뀌어도 PPPL과 downstream 결과가 달라지는가?

Table 1: Glot500 original head/tail/all reference table from Imani et al. [2023]. Values are averages across five seeds; retrieval, tagging, classification, and roundtrip values are percentages.

Metric	tail			head			all		
	XML-R-B	XML-R-L	Glott500-m	XML-R-B	XML-R-L	Glott500-m	XML-R-B	XML-R-L	Glott500-m
Pseudoperplexity	304.2	168.6	12.2	12.5	8.4	11.8	247.8	136.4	11.6
Sentence Retrieval Tatoeba	32.6	33.6	59.8	66.2	71.1	75.0	56.6	60.4	70.7
Sentence Retrieval Bible	7.4	7.1	43.2	54.2	58.3	59.0	19.3	20.1	47.3
Text Classification	13.7	13.9	46.6	51.3	60.5	54.7	23.3	25.8	48.7
NER	47.5	51.8	60.7	61.8	66.0	63.9	55.3	59.5	62.4
POS	41.7	43.5	62.3	76.4	78.4	76.0	65.8	67.7	71.8
Roundtrip Alignment	2.6	3.1	4.5	3.4	4.1	5.5	2.8	3.3	4.7

3. sentence representation space에서도 언어별 identity 또는 family/typology 구조가 관찰되는가?

중요한 claim boundary는 다음과 같다. 본 실험은 511개 language-script를 학습한 full Glot500 reproduction이 아니다. 또한 v5.2 Target7은 모두 Latin script이므로 script diversity 자체를 주장하지 않는다. 대신 XML-R-unseen tail language 중 downstream 평가가 가능한 가장 작은 corpus band를 선택하여 initialization ablation을 정밀하게 비교한다.

2 Related Work

2.1 Glot500 and Horizontal Scaling

Glott500은 XML-R이 지원하는 약 100개 언어를 head language로, 그 밖의 언어를 tail language로 정의하고, multilingual model의 horizontal scaling을 제안한다 [Imani et al., 2023]. 원 논문은 language-script 단위 corpus cleaning, 30,000 sentence' 이상 기준, SentencePiece unigram tokenizer 재학습, XML-R vocabulary 확장, continued MLM pretraining을 하나의 pipeline으로 구성한다. Glott500-m은 XML-R vocabulary 250K에 약 151K new token을 추가해 401K vocabulary를 만들고, 600GB corpus에서 MLM으로 continued pretraining한다.

원 논문 Table 4는 Glott500-m이 tail group에서 특히 큰 개선을 보인다고 보고한다. 본 보고서에서는 그 표를 단순 baseline으로 가져오는 데 그치지 않고, 왜 본 실험이 같은 head/tail/all reporting structure를 따라야 하는지의 근거로 사용한다.

2.2 SentencePiece Unigram and Vocabulary Extension

SentencePiece는 library 이름이고, 그 안에서 BPE 또는 unigram language model을 사용할 수 있다 [Kudo and Richardson, 2018]. XML-R과 Glott500은 SentencePiece unigram 계열을 사용한다. Unigram LM은 가능한 subword 후보 집합을 크게 시작한 뒤, EM으로 token probability를 추정하고 likelihood contribution이 낮은 token을 pruning하는 top-down 방식이다. 이 선택은 BPE처럼 greedy merge만 누적하는 방식과 달리 여러 segmentation 후보를 확률적으로 다룬다.

본 프로젝트의 tokenizer는 이 Glott500 흐름을 따른다. tokenization/run.py는 --model_type=unigram, --byte_fallback=true, --character_coverage=1.0으로 새 SentencePiece model을 학습하고, 기존 XML-R SentencePiece protobuf에 없는 piece만 append한다.

2.3 Embedding Initialization for New Tokens

Vocabulary expansion 연구에서는 새 token을 추가한 뒤 embedding을 어떻게 초기화할지가 중요하다. Yamaguchi et al.은 30K sentences, 약 0.01GB target language text만 있는 low-resource setting에서 vocabulary expansion과 target parameter initialization을 비교하고, high-resource에서 자주 쓰이는 random initialization이 항상 최선이 아니라고 보고한다 [Yamaguchi et al., 2025]. Mean initialization은 기존 embedding centroid를 사용하고, FVT 계열은 새 token surface

Table 2: Target7 selection. All target languages are XLM-R-unseen Glot500 raw languages with at least 30,000 sentence’ units and useful downstream overlap.

language-script	full name	region	script	new_length	covered tasks
dtb_Latn	Kadazan Dusun	Southeast Asia	Latn	48,468	Tatoeba, Bible, Roundtrip, Taxi1500, Embedding similarity
xav_Latn	Xavante	South America	Latn	31,765	Bible, Roundtrip, POS, Taxi1500
bam_Latn	Bambara	West Africa	Latn	32,150	Bible, Roundtrip, POS, Taxi1500
csb_Latn	Kashubian	Europe	Latn	33,743	Tatoeba, NER, Embedding similarity
ile_Latn	Interlingue	Constructed/Europe	Latn	40,984	Tatoeba, Embedding similarity
lij_Latn	Ligurian	Europe	Latn	42,447	NER, POS
fur_Latn	Friulian	Europe	Latn	30,052	NER

를 source tokenizer로 다시 분해한 뒤 source subtoken embedding을 평균한다 [Hewitt, 2021, Jung, 2026].

본 연구는 decoder LLM이 아니라 XLM-R encoder 기반 MLM setting이지만, 질문은 같다. 새 token row를 완전히 무작위로 시작할지, 기존 XLM-R tokenizer와 embedding space가 이미 가진 표면형 정보를 재사용할지 비교한다.

3 Data

3.1 Target Definition

v5.2의 corpus universe는 ‘99’ language-script이다. 이 중 ‘92’개는 XLM-R training language로 표시된 seen/head language이고, ‘7’개는 XLM-R-unseen target tail language이다. 초기 feedback은 “low-resource language를 task별 3개씩 포함하도록 고른 이유”를 더 명확히 요구했다. 이에 따라 target은 단순히 가장 작은 corpus가 아니라 다음 조건으로 정의한다.

XLM-R-unseen tail languages in the smallest Glot500 corpus band that still supports downstream evaluation.

strict ‘new_length <= 10k’ non-XLM-R tail language는 local task-list membership이 없어 Tatoeba, Bible, NER, POS 등을 3개씩 채울 수 없다. 따라서 downstream evidence를 확보하기 위해 약 30K–50K Glot500 sentence’ band에서 task overlap이 가장 큰 7개 언어를 선택했다. 이 결정은 docs/exp/v5.2/1_data_scope/low_resource_task_fill_candidates_ko.md와 preprocessing/prepare_v5_glot50010_merge_inputs.py의 V52_OVERLAP_TASKFILL_GLOT5007에 기록되어 있다.

3.2 Task Coverage

Target7은 총 21개 task slot을 7개 언어로 압축한다. 이 표는 왜 downstream task를 사용할 수 있는지, 그리고 어떤 결과를 target evidence로 말할 수 있는지의 근거이다.

3.3 Training Corpus

MLM training corpus는 preprocessing/run_v52_glot5007_merge.sh가 preprocessing/merge_files.py를 호출하여 만든다. Sampling은 Glot500-style language sampling factor $\alpha = 0.3$ 을 사용한다.

$$P_i \propto n_i^\alpha$$

여기서 n_i 는 language-script i 의 corpus size이다. $\alpha = 1$ 이면 head language가 corpus 크기만큼 압도적으로 자주 뽑히지만, $\alpha = 0.3$ 은 head/tail ratio를 완화한다. 예를 들어 1,000,000 sentence head와 1,000 sentence tail은 $\alpha = 1$ 에서 1000:1이지만, $\alpha = 0.3$ 에서는 약 8:1 수준으로 줄어든다. v5.2 merge report의 핵심 수치는 다음과 같다.

Table 3: Downstream coverage rationale for Target7. This table is the defense artifact for why the target set is not the strict smallest corpus set.

Task	target languages	current status
Tatoeba retrieval	csb_Latn, ile_Latn	dtp_Latn, ready local pairs
Bible retrieval	dtp_Latn, bam_Latn	xav_Latn, materialized parallel verses
Roundtrip alignment	dtp_Latn, bam_Latn	xav_Latn, Bible-derived JSONL
NER	csb_Latn, fur_Latn	lij_Latn, PAN-X train/dev/test ready
POS	xav_Latn, lij_Latn	bam_Latn, rebuilt/materialized split
Taxi1500	dtp_Latn, bam_Latn	xav_Latn, not target7 evidence in current draft
Embedding similarity	csb_Latn, ile_Latn	dtp_Latn, diagnostic pairs ready

Item	Samples
seen/head training samples	4,147,176
target7 training samples	335,083
total MLM training samples	4,482,259

이 값은 docs/exp/v5.2/LIVE_STATUS.md 및 docs/exp/v5.2/0_tokenizer/merge/Glot500_v52_glot5007_xlmr100.report.json의 ready/PASS 상태와 일치한다.

4 Method

4.1 Tokenizer Extension

Tokenizer는 Glot500-style로 고정한다. `tokenization/train_v52_glot5007.sh`는 먼저 XLM-R-base tokenizer의 `sentencepiece.bpe.model`을 output directory에 복사한다. 그 다음 `tokenization/run.py`가 mixed corpus에서 SentencePiece unigram model을 학습한다. 사용된 핵심 설정은 다음과 같다.

- `--model_type=unigram`: Glot500 및 XLM-R 계열과 맞춘다.
- `--byte_fallback=true`: 기존 subword로 처리되지 않는 문자를 UTF-8 byte piece로 분해한다.
- `--character_coverage=1.0`: target7의 Latin-script 문자를 모두 보존한다.
- `--input_sentence_size=20000000`: 전체 corpus를 scan 하되 20M sentence sample로 SPM memory 사용을 통제한다.

학습된 auxiliary SentencePiece model에서 기존 XLM-R SPM에 없는 piece만 protobuf에 append한다. 이 방식은 HuggingFace tokenizer의 `add_tokens()`를 쓰는 v3류 실험보다 Glot500 원 논문 구현에 가깝다. 단, SPM protobuf를 직접 수정하면 `<mask>` id가 이동할 수 있으므로 initialization 단계에서 token id prefix가 아니라 token string identity로 source row를 복사해야 한다.

Table 4: Embedding initialization methods. The tokenizer, corpus, and MLM schedule are fixed across methods.

Method	Definition	Interpretation
RANDOM	New rows are sampled from the model initialization distribution, approximately $\mathcal{N}(0, 0.02)$.	Baseline matching the simplest Glot500-style resize behavior.
MEAN	New lexical rows are set to the global mean of existing source lexical embeddings.	Stable centroid baseline; does not use token surface information.
FVT	A new token surface is retokenized by the source XLM-R tokenizer; its source subtoken embeddings are averaged.	Reuses source subword morphology/orthography; main hypothesis.
WEIGHTED FVT	FVT source subtoken embeddings are averaged with surface-length weights.	Tests whether longer source subtokens carry more useful lexical signal.
FAMILY-AWARE MEAN	Token provenance is mapped to language family; new rows use frequency-weighted family source-token means.	Tests family/typology prior instead of pure surface decomposition.

4.2 Embedding Initialization

모든 method는 같은 tokenizer, 같은 corpus, 같은 MLM schedule을 사용한다. 따라서 차이는 새 vocabulary row의 초기값에서 온다.

구현은 `scripts/build_v5_initialized_checkpoint.py`에 있다. 이 script는 source tokenizer와 target tokenizer를 모두 읽은 뒤, source token과 동일한 string을 가진 target row는 source embedding row를 그대로 복사한다. 새 token에 대해서만 method별 초기화를 적용한다. 또한 `<mask>` token이 source id 250001에서 target tokenizer의 마지막 id로 이동할 수 있으므로, 해당 row를 token identity 기준으로 명시적으로 remap하고 `mask_max_abs_diff_after_copy`를 검증한다.

4.3 Continued MLM Pretraining

MLM training은 `modeling/train_v52_glot5007_mlm.sh`가 `modeling/run.py`를 호출한다. `modeling/run.py`는 HuggingFace `run_mlm.py`를 바탕으로 한 local variant이며, `AutoModelForMaskedLM`, `DataCollatorForLanguageModeling`, `Trainer`를 사용한다. Text는 tokenizer로 encoding된 뒤 max length 512 chunk로 concatenate/grouping되고, collator가 MLM probability 0.15로 masked token batch를 만든다.

Item	Setting
base model	<code>xlm-roberta-base</code>
objective	MLM
learning rate	5×10^{-5}
Adam betas	(0.9, 0.999)
effective batch	384
max length	512
MLM probability	0.15
checkpoint interval	1000 steps
main convergence budget	50K steps for five-way comparison

5 Experiments

5.1 Evaluation Surface

평가는 Glot500 논문이 사용한 metric family를 유지한다. 다만 local target7 coverage가 task마다 다르므로, 결과 표에는 metric value와 함께 coverage를 반드시 보고한다.

- Pseudoperplexity: MLM이 target sentence를 얼마나 자연스럽게 예측하는지 측정한다. 낮을수록 좋다.
- Sentence Retrieval Tatoeba/Bible: English-aligned sentence를 top- k retrieval로 찾는다. Top-10 accuracy를 사용한다.
- Text Classification: Taxi1500 계열 macro-F1을 사용하지만, 현재 local target7 direct evidence가 아니므로 해석을 제한한다.
- NER/POS: sequence labeling F1을 사용한다. NER는 target7 중 3개, POS는 target-relevant 3개가 있다.
- Roundtrip Alignment: Bible-derived multi-way alignment가 원래 word로 돌아오는지를 accuracy로 측정한다.

평가runner는 evaluation/ 아래에 유지되어 있으며, v5.2 결과는 docs/exp/v5.2/3_evaluation/ 아래에 metric 별로 저장되어 있다. Final 50K table은 docs/exp/v5.2/3_evaluation/09_aggregation/main_head_tail_all.tsv 형식으로 method별 head/tail/all row를 재생성해 채운다. 기존 docs/exp/v5.2/3_evaluation/v52_final_downstream_table.tsv는 step-4000 RANDOM/MEAN/FVT early diagnostic 근거로만 둔다.

5.2 Main Comparison

Main ablation은 50K-step convergence run에서 생성된 RANDOM, MEAN, FVT, WEIGHTED FVT, FAMILY-AWARE MEAN checkpoint를 비교한다. Step-4000 RANDOM/MEAN/FVT table은 early diagnostic으로 appendix에 남기되, final report의 main table은 동일한 final checkpoint policy를 적용한 5-way head/tail/all table로 대체한다. 이렇게 해야 각 method가 같은 tokenizer, corpus, MLM objective, evaluation protocol뿐 아니라 같은 convergence budget에서도 비교된다.

5.3 Figures Planned for the Report

보고서 본문에는 세 종류의 plot을 넣는다.

1. Tokenization effect: target7 tokens/word reduction. Source: docs/exp/v5.2/0_tokenizer/03_tokenization_effect/tokenization_effect_change.png.
2. Initialization convergence: method별 MLM training loss 및 PPPL trajectory. Source: docs/exp/v5.2/2_training/convergence_5way_loss_curve.png 및 docs/exp/v5.2/3_evaluation/v52_checkpoint_score_table.tsv.
3. Representation geometry: 38-language family similarity / centroid map. Source: docs/exp/v5.2/3_evaluation/09_family_similarity/.




Figure 1: Target7 tokenization fertility reduction. All initialization variants share this tokenizer; therefore method-to-method result differences cannot be explained by tokenizer fertility alone.

Table 5: Final 50K head/tail/all reporting grid. Each row should be filled from the completed 50K evaluation aggregation. Cells without task coverage should be marked NA rather than treated as zero.

Metric	Group	Score	Random	Mean	FVT	Weighted FVT	Family-aware mean	Coverage note
Pseudoperplexity	tail/head/all	PPPL ↓	TBD	TBD	TBD	TBD	TBD	lower is better
Tatoeba retrieval	tail/head/all	Acc10 ↑	TBD	TBD	TBD	TBD	TBD	report available languages per group
Bible retrieval	tail/head/all	Acc10 ↑	TBD	TBD	TBD	TBD	TBD	target group may be NA if no coverage
Text classification	tail/head/all	macro-F1 ↑	TBD	TBD	TBD	TBD	TBD	target group may be NA if no coverage
NER	tail/head/all	F1 ↑	TBD	TBD	TBD	TBD	TBD	include language count per group
POS	tail/head/all	F1 ↑	TBD	TBD	TBD	TBD	TBD	include language count per group
Roundtrip alignment	tail/head/all	Acc. ↑	TBD	TBD	TBD	TBD	TBD	target group may be NA if no coverage

6 Results

6.1 Tokenizer Fertility

동일한 target7 raw sentence 3,500개에 대해 XLM-R tokenizer와 v5.2 extended tokenizer를 비교 하면, tokens/word가 2.204에서 1.592로 감소한다. 평균 reduction은 27.75%이다. 이는 Glot500-style vocabulary extension이 실제로 tail language의 subword fragmentation을 줄였다는 근거이다.

6.2 50K Five-Way Convergence Results

Final result의 중심 표는 50K-step convergence run에서 얻은 다섯 initialization checkpoint를 같은 row schema로 비교한다. 각 metric은 RANDOM, MEAN, FVT, WEIGHTED FVT, FAMILY-AWARE MEAN을 모두 포함하고, group은 tail/target, head, all로 나눈다. Task coverage가 없는 group은 0점처럼 쓰지 않고 “not available”로 표시한다.

6.3 Step-4000 Early Diagnostic

Step-4000 diagnostic에서 FVT는 PPPL, Tatoeba retrieval, Bible retrieval, NER, POS, roundtrip alignment에서 가장 좋다. Text classification은 MEAN이 가장 높으므로, 보고서에서는 FVT를 “모든 task에서 항상 최고”라고 쓰지 않는다. 더 정확한 문장은 다음과 같다.

같은 tokenizer와 corpus를 공유하는 controlled setup의 early checkpoint에서 FVT는 intrinsic MLM과 retrieval/alignment 계열에서 강한 initialization signal을 보인다.

Table 6: v5.2 step-4000 early diagnostic ablation. Values are target-focused/local available rows from docs/exp/v5.2/3_evaluation/v52_final_downstream_table.tsv. This table motivates the 50K five-way run; it is not the final convergence result.

Metric	Score	Random	Mean	FVT	Best
Pseudoperplexity	weighted PPPL ↓	119.582	128.259	58.026	FVT
Tatoeba retrieval	Acc10 ↑	0.249	0.246	0.283	FVT
Bible retrieval	Acc10 ↑	0.0064	0.0061	0.0064	FVT
Text classification	macro-F1 ↑	0.697	0.778	0.713	Mean
NER	F1 ↑	0.377	0.405	0.484	FVT
POS	F1 ↑	0.507	0.507	0.519	FVT
Roundtrip alignment	accuracy ↑	0.0188	0.0218	0.0262	FVT

Table 7: PPPL trajectory under short continued MLM pretraining. Lower is better.

Method	step 500	step 1000	step 2000	step 3000	step 4000
RANDOM	374.61	241.80	160.50	133.11	119.58
MEAN	479.42	270.93	172.58	138.51	128.26
FVT	161.88	108.60	75.26	61.60	58.03

6.4 Early PPPL Trajectory

4K step 이하의 짧은 continued pretraining에서도 FVT는 처음부터 낮은 PPPL을 유지한다. 이는 source tokenizer로 새 token surface를 재분해해 기존 embedding 정보를 재사용한 효과로 해석할 수 있다. 다만 이 표는 convergence result가 아니라 early diagnostic이다.

6.5 Why the Convergence Plot Is Drawn This Way

Figure 2 is not just a decorative training curve. It is an argument for whether the initialization comparison has reached a point where final performance claims are defensible. The title, axes, point interval, and 50K queue all encode experimental decisions.

- **Title.** “v5.2 MLM Loss Trajectory: Prior Run + Continuation” states that the figure combines the earlier 8h diagnostic run and the later convergence continuation, rather than showing only a fresh single run.
- **X-axis.** “Weighted-FVT-aligned training step (1K grid)” is used because the prior and continuation phases did not have identical raw step accounting. The plot converts exposure to a shared batch-36-equivalent scale and snaps it to the weighted-FVT 1K grid.
- **Y-axis.** “MLM training loss” is the Trainer logging loss from continued masked language modeling. This axis is used for convergence diagnosis, not as a direct downstream score.
- **Point interval.** Points are displayed every 1000 aligned steps because v5.2 saves/logs checkpoints at 1000-step intervals. This is also the granularity at which downstream/PPPL checkpoint comparisons can be attached without inventing intermediate measurements.
- **Why continue beyond 4K.** The 4K result is an early diagnostic. Earlier notes show that PPPL improvement slowed near 4K, but training loss was still decreasing, so 4K cannot be called convergence.




Figure 2: v5.2 MLM loss trajectory for prior run plus continuation. The x-axis is a weighted-FVT-aligned 1K training-step grid so that prior and continuation segments with different effective batch accounting can be compared on the same exposure scale. Circle markers are displayed 1K-grid points; square markers are final saved models. Raw loss values are preserved in `convergence_5way_loss_curve.tsv`; the plotted display loss includes documented plot-only bridging/smoothing around the prior-to-continuation transition.

- **Why a 50K queue.** The 50K queue is a conservative upper bound for testing flattening across all five initialization methods under the same global batch 36 exposure. It was chosen after the 4K/8K checks were judged insufficient for a final convergence claim. The final report can stop using earlier checkpoints once the loss-drop summary and downstream trajectory show a stable plateau.
- **Markers and colors.** One line is drawn per initialization method. Circle markers indicate regular displayed grid points, while square markers indicate final saved models. The colors are fixed in `scripts/plot_v52_convergence_loss.py` so the same method has the same visual identity across regenerated plots.
- **Smoothing disclosure.** The graph applies plot-only transition smoothing/bridging for readability near the prior-to-continuation boundary. This does not overwrite raw measurements; the TSV retains `loss`, `display_loss`, and `display_loss_source`.

6.6 Glot500-Style Reporting Rule

Feedback asked that final tables follow Glot500’s head/tail/all framing. The final report therefore uses the same three group views for every metric where coverage exists. This prevents a target-only improvement from being overstated as a global multilingual gain, and it also makes regressions on head languages visible.

7 Representation Analysis

7.1 Sentence Embedding Extraction

Sentence representation analysis follows the Glot500 retrieval-style encoder usage. Each raw sentence is encoded with the model tokenizer, passed through `AutoModel`, and hidden states from layer index 7 are used. Special tokens and padding are excluded, token hidden states are




Figure 3: FVT step-4000 family similarity diagnostics. These figures are diagnostic analysis, not an official Glot500 metric.

mean-pooled, and sentence vectors are L2-normalized. For centered cosine analysis, the global sentence-vector mean is subtracted before normalization. A language centroid is the mean of that language’s sentence vectors.

7.2 Family/Typology Structure

The v5.2 family similarity diagnostic samples 38 languages and 3,708 sentence points. The key claim is deliberately modest: the sentence representation space shows observable language identity and family/typology structure, not perfect cluster separation. Since all Target7 languages use Latin script, the analysis is useful precisely because it separates “same script only” from “same family” relationships.

FVT step-4000 centered cosine scores show the expected ordering: same-language tail pairs are closest; tail-tail same-family pairs are closer than same macro-family; both are closer than different-family pairs. Tail-head pairs that only share Latin script are weaker than family-based relations. This supports the interpretation that the model is not merely grouping by script.

Relation type	Pairs	Mean centered cosine
tail within language	350	0.473
tail-tail same family	50	0.307
tail-tail same macro-family	100	0.182
tail-tail different family	900	0.124
tail-head same family	1,050	0.037
tail-head different family, same Latn script	6,100	-0.050
tail-head different family, different script	1,856	-0.079

8 Limitations and Conclusion

8.1 Limitations

본 실험은 매우 좋은 방향성을 갖고 있지만, final report에서는 다음 제한을 분명히 써야 한다.

- Full 511-language Glot500 reproduction 이 아니라, 92 seen + 7 target 의 controlled subset 실험이다.
- Target7 은 모두 Latin script 이므로 script-diversity claim 은 하지 않는다.

- PPPL은 v5.2 diagnostic setup에서 계산되었고, Glot500 원 논문의 held-out test PPPL과 동일하다고 쓰면 안 된다.
- Text classification은 현재 target7 direct evidence가 아니라 local English/available-row evidence로 다뤄야 한다.
- Step-4000 result는 early diagnostic으로만 사용하고, final claim은 50K-step five-way convergence result로 제한한다.
- WEIGHTED FVT와 FAMILY-AWARE MEAN은 v5.2 local exploratory ablation이므로 기존 문헌 방법과 같은 수준의 established method로 과장하지 않는다.
- FVT는 대부분 metric에서 강하지만 POS target subset과 text classification처럼 예외가 있으므로 “always best” claim은 피한다.

8.2 Conclusion

Glott500-style tokenizer extension은 target7에서 subword fertility를 크게 줄였다. 그러나 RANDOM, MEAN, FVT, WEIGHTED FVT, FAMILY-AWARE MEAN이 같은 tokenizer를 공유하기 때문에, method 간 PPPL/downstream 차이는 tokenizer만으로 설명되지 않는다. Step-4000 diagnostic에서는 source-tokenizer decomposition 기반 FVT가 강한 초기 신호를 보였지만, 최종 결론은 50K-step five-way convergence 결과에서 loss flattening, PPPL trajectory, downstream score가 함께 확인된 범위 안에서만 제시한다. 이는 low-resource vocabulary extension에서 새 token row를 완전히 무작위로 시작하기보다 기존 XLM-R embedding 정보 또는 corpus provenance를 어떻게 재사용할지 결정하는 초기화 선택이 중요한 실험 변수임을 보여준다.

최종 term paper에서는 이 주장을 더 단단하게 만들기 위해 head/tail/all table을 완성하고, loss curve와 PPPL trajectory, target language별 downstream breakdown, sentence representation geometry를 함께 제시한다. 이 프로젝트는 실험 로그와 claim boundary가 잘 남아 있어서, 과장 없이도 충분히 설득력 있는 report로 발전시킬 수 있다.

References

- Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzman, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, 2020. URL <https://aclanthology.org/2020.acl-main.747/>.
- John Hewitt. Initializing new word embeddings for pretrained language models. <https://www.cs.columbia.edu/~johnhew/vocab-expansion.html>, 2021.
- Ayyoob Imani, Peiqin Lin, Amir Hossein Kargaran, Silvia Severini, Masoud Jalili Sabet, Nora Kassner, Chunlan Ma, Helmut Schmid, Andre F. T. Martins, Francois Yvon, and Hinrich Schuetze. Glot500: Scaling multilingual corpora and language models to 500 languages. In *Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics*, 2023. URL <https://aclanthology.org/2023.acl-long.61/>.
- Moon-Ryul Jung. Vocabulary extension and embedding initialization for fine-tuning foundational llms, 2026. Course notes, local file: docs/survey/vocab_extension_tutorial.pdf.
- Taku Kudo and John Richardson. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 66–71, 2018. URL <https://aclanthology.org/D18-2012/>.

Atsuki Yamaguchi, Aline Villavicencio, and Nikolaos Aletras. How can we effectively expand the vocabulary of llms with 0.01gb of target language text? *Computational Linguistics*, 2025. URL <https://arxiv.org/abs/2406.11477>. Accepted article; arXiv:2406.11477v3.

A Artifact and Code Map

Table 8: Reproducibility map for the v5.2 report draft.

Stage	Code / artifact	Role in report
Target selection	<code>preprocessing/prepare_v5_glot50010_merge_inputs.py</code>	Defines <code>V52_OVERLAP_TASKFILL_GLOT5007</code> ; validates XLM-R-unseen status, min 30K sentence count, and raw-dir existence.
Corpus prepare	<code>preprocessing/run_v52_glot5007_prepare.sh</code>	Creates target manifest and stats CSV for 92+7 setup.
Corpus merge	<code>preprocessing/run_v52_glot5007_merge.sh</code> , <code>preprocessing/merge_files.py</code>	Builds sampled MLM corpus with $\alpha = 0.3$, manifest, and JSON report.
Tokenizer	<code>tokenization/train_v52_glot5007.sh</code> , <code>tokenization/run.py</code>	Trains SentencePiece unigram tokenizer, enables byte fallback, appends new pieces to XLM-R SPM protobuf.
Initialization	<code>scripts/run_v52_build_initializers.sh</code> , <code>scripts/build_v5_initialized_checkpoint.py</code>	Builds random/ mean/ FVT/ weighted-FVT/family-aware mean initialized checkpoints; copies rows by token identity and checks mask remap.
MLM training	<code>modeling/train_v52_glot5007_mlm.sh</code> , <code>modeling/run.py</code>	Runs continued MLM with max length 512, LR $5e - 5$, Adam betas (0.9, 0.999), MLM prob 0.15.
Evaluation	<code>evaluation/retrieval/</code> , <code>evaluation/tagging/</code> , <code>evaluation/round-trip/</code> , <code>evaluation/text_classification/</code>	Provides PPPL, retrieval, NER/ POS, roundtrip, and text-classification metric families.
Aggregation	<code>docs/exp/v5.2/3_evaluation/v52_final_downstream_table.tsv</code>	Source for step-4000 initialization ablation table.
Live status	<code>docs/exp/v5.2/LIVE_STATUS.md</code>	Records which initializers/training runs are complete, missing, or running.

B Draft Writing Notes

이 LaTeX draft는 final submission 직전 다음 항목을 확인해야 한다.

- `docs/exp/v5.2/LIVE_STATUS.md`의 latest status로 50K five-way convergence/evaluation 완료 여부를 갱신한다.

- Step-4000 diagnostic table은 docs/exp/v5.2/3_evaluation/v52_final_downstream_table.tsv 근거로 유지하되 final claim에 사용하지 않는다.
- head/tail/all final table은 docs/exp/v5.2/3_evaluation/09_aggregation/main_head_tail_all.tsv 형식으로 50K checkpoint 별 group row를 재생성해 채운다.
- 논문 제출용 PDF에는 [TODO: course name, student id, exact page limit]를 채운다.